Plan prévisionnel

Dataset retenu

Le jeu Flipkart, déjà exploré au projet 6 : **1 050 produits** d'une place de marché indienne, chacun avec une photo, un nom et une description. La cible est le premier niveau de l'arborescence produit, soit **7 catégories parfaitement équilibrées** (150 images chacune) : Baby Care, Beauty and Personal Care, Computers, Home Decor & Festive Needs, Home Furnishing, Kitchen & Dining, Watches. Je n'utilise que les images, très hétérogènes (de 145 à plus de 11 000 pixels de côté, fonds studio ou mises en scène). Enjeu métier : ranger automatiquement un nouvel article à partir de sa seule photo.

Modèle envisagé

DINOv2 (Meta AI, avril 2023) est un modèle de fondation pour la vision : un Vision Transformer pré-entraîné **sans aucune étiquette**, par auto-distillation, sur 142 millions d'images sélectionnées automatiquement. Il produit une représentation générale de l'image, utilisable telle quelle (modèle gelé) pour classer, rechercher des images similaires ou segmenter. Il vise les cas où les données étiquetées sont rares, comme ici avec quelques centaines d'images par entraînement.

- **Plus performant :** sur ImageNet, une simple couche linéaire posée sur DINOv2 ViT-B/14 gelé atteint 84,5 % de bonnes réponses, contre 71,9 % pour MobileNetV2 pourtant entraîné de bout en bout (chiffres publiés par Meta et par torchvision pour les poids utilisés ici). Les auteurs montrent aussi qu'il dépasse OpenCLIP, la meilleure représentation généraliste jusque-là, sur la plupart des tests, au niveau de l'image comme du pixel.
- **Adapté au projet :** pas de réentraînement du réseau, donc compatible avec un petit jeu de données et une machine modeste ; poids libres (licence Apache 2.0) sur Hugging Face.
- **Interprétable :** ses cartes d'attention localisent l'objet sans supervision, ce qui servira à expliquer chaque prédiction.

Références bibliographiques

1. Oquab M. et al. (2023), **DINOv2: Learning Robust Visual Features without Supervision**, arXiv:2304.07193 ; illustré par Rafaat Y. (24 mai 2023), « DINOv2: Self-Supervised Computer Vision Models by Meta AI », KDnuggets.

2. Caron M. et al. (2021), **Emerging Properties in Self-Supervised Vision Transformers** (DINO), arXiv:2104.14294 : le principe de l'auto-distillation et des cartes d'attention.

3. Sandler M. et al. (2018), **MobileNetV2: Inverted Residuals and Linear Bottlenecks**, arXiv:1801.04381 : l'architecture de la baseline.

Code réutilisé : l'exemple d'extraction de la fiche Hugging Face facebook/dinov2-base et le chargement des données de mon projet 6. L'application, elle, est originale (jeu Flipkart).

Démarche de test du nouvel algorithme (preuve de concept)

- **Baseline :** MobileNetV2 pré-entraîné sur ImageNet, gelé, surmonté d'un classifieur. C'est l'approche retenue au projet 6 (82,4 % de bonnes réponses), reproduite dans le même notebook que le nouveau modèle. J'ajoute ResNet50 (23,5 M de paramètres) et DINOv2 ViT-S/14 (22,1 M) : à taille comparable, ils montrent si le gain vient de la méthode et pas seulement de la taille du modèle.
- **Nouvelle méthode :** DINOv2 ViT-B/14 gelé, surmonté du même classifieur (régression logistique). Mêmes images, même préparation : seule la représentation de l'image change, la comparaison est donc équitable.
- **Évaluation :** validation croisée stratifiée en 5 plis, les réglages étant choisis à l'intérieur de chaque pli. Chaque image est prédite une fois par un modèle qui ne l'a jamais vue, ce qui permet un test de McNemar sur les 1 050 images. Métrique principale : l'exactitude (classes équilibrées), complétée par le F1 macro, la matrice de confusion, le temps de prédiction et la taille du modèle.
- **Interprétabilité :** cartes d'attention et occlusion pour expliquer une image (locale), moyennes par catégorie (globale).
- **Démonstration :** dashboard Streamlit déployé sur Hugging Face Spaces : analyse exploratoire, choix ou envoi d'une image, prédiction des deux modèles, critères d'accessibilité WCAG.