Note méthodologique : preuve de concept

Dataset retenu

Le jeu de données est celui du projet 6 : 1 050 produits vendus sur Flipkart, une grande place de marché en ligne indienne. Chaque produit a une photo, un nom, une description et une arborescence de catégories du type « Home Furnishing >> Curtains & Accessories >> Curtains ». La catégorie à prédire est le premier niveau de cette arborescence.

Il y a 7 catégories, avec exactement 150 produits chacune : Baby Care, Beauty and Personal Care, Computers, Home Decor & Festive Needs, Home Furnishing, Kitchen & Dining, Watches. Comme les classes sont parfaitement équilibrées, un modèle qui répondrait au hasard aurait 1 chance sur 7 (14 %) d'avoir juste, et la part de bonnes réponses (l'exactitude) est une mesure fiable de la performance.

Je n'utilise que les photos. Le texte du projet 6 n'est pas repris, pour que la comparaison porte sur une seule question : quel réseau transforme le mieux une image en description exploitable. Les photos sont très hétérogènes : de 145 à plus de 11 000 pixels de côté, souvent pas carrées, sur fond blanc de studio ou dans une mise en scène.

Deux choix de préparation découlent de cette exploration. D'abord, les images sont complétées en carré avec du blanc avant d'être réduites à 224 × 224 pixels, la taille attendue par les réseaux : le projet 6 les étirait directement, ce qui déformait les produits allongés. Ensuite, j'ai cherché les photos en double grâce à une empreinte de l'image réduite à 8 × 8 pixels. Il y a 258 paires de quasi-doublons, des variantes d'un même article, dont 13 rangées dans deux catégories différentes. Les quasi-doublons sont gardés ensemble lors du découpage en plis de validation (933 groupes pour 1 050 images), pour qu'un modèle ne soit jamais testé sur une copie d'une image qu'il a apprise.

L'enjeu métier : ranger automatiquement un nouvel article dans la bonne catégorie à partir de sa photo, pour réduire la saisie manuelle des vendeurs. Chaque erreur se traduit par un produit mal rangé, donc moins visible pour les acheteurs qui le cherchent : l'exactitude mesure directement la part d'articles bien rangés.



Figure 1 : une photo par catégorie (notebook, section 1).

Les concepts de l’algorithme récent

Le problème que DINOv2 cherche à résoudre

Pour classer une image, on passe d'abord par une représentation : un réseau pré-entraîné transforme l'image en un vecteur de quelques centaines de nombres qui la décrit. Au projet 6, ce réseau était MobileNetV2, entraîné de façon supervisée sur ImageNet : il a appris à reconnaître 1 000 catégories d'images à partir de 1,3 million de photos étiquetées à la main. Sa

représentation est donc taillée pour ces 1 000 catégories-là, et étiqueter beaucoup plus d'images coûterait très cher.

DINOv2 (Meta AI, 2023) apprend sa représentation sans aucune étiquette, sur 142 millions d'images. L'objectif des auteurs est d'obtenir une représentation générale, utilisable telle quelle sur n'importe quel jeu d'images, sans réentraîner le réseau.

Un Vision Transformer : l'image découpée en morceaux

DINOv2 n'est pas un réseau convolutif mais un Vision Transformer (ViT), l'architecture des modèles de langage adaptée aux images. L'image de 224 × 224 pixels est découpée en une grille de 16 × 16 = 256 carrés de 14 × 14 pixels, appelés patchs (d'où le nom ViT-B/14). Chaque patch devient un vecteur, appelé jeton, comme un mot dans une phrase. On ajoute un jeton spécial, [CLS], qui ne correspond à aucun morceau de l'image et dont le rôle est d'en construire le résumé.

Ces jetons traversent 12 couches. Dans chaque couche, le mécanisme d'attention permet à chaque jeton de regarder tous les autres et de décider lesquels comptent pour lui : un patch de bracelet peut s'appuyer sur un patch de cadran situé à l'autre bout de l'image. Un réseau convolutif, lui, ne combine au départ que des pixels voisins. Le modèle utilisé ici (ViT-B/14) a 12 « têtes » d'attention par couche, qui regardent chacune l'image à leur façon, et des jetons de 768 nombres.

Apprendre sans étiquettes : l'auto-distillation

La méthode reprend DINO (Caron et al., 2021). Deux copies du même réseau travaillent ensemble : un élève et un professeur. On découpe dans une même photo plusieurs vues : de grands recadrages et de petits morceaux. Le professeur voit les grandes vues, l'élève voit toutes les vues, et l'élève doit produire pour son jeton [CLS] la même réponse que le professeur. Pour y arriver, il doit comprendre qu'un petit morceau de cadran et la montre entière montrent le même objet : il apprend le contenu de l'image, sans qu'on lui dise jamais ce que c'est.

Le professeur n'est pas entraîné directement : ses poids sont une moyenne glissante des poids de l'élève au fil de l'entraînement, ce qui le rend plus stable. Le danger de ce type d'apprentissage est que les deux réseaux s'entendent sur une réponse constante, identique pour toutes les images. DINOv2 l'empêche en rééquilibrant les réponses du professeur sur chaque lot d'images (une normalisation dite de Sinkhorn-Knopp), pour qu'elles restent variées.

Les ajouts de DINOv2

Au niveau des patchs, DINOv2 ajoute l'objectif d'iBOT : on masque une partie des patchs dans l'image de l'élève, et il doit retrouver ce que le professeur, qui voit l'image entière, produit pour ces patchs masqués. C'est ce qui donne au modèle une compréhension locale, patch par patch, et pas seulement globale. Un terme supplémentaire, appelé régularisation KoLeo, pousse les représentations des images d'un même lot à s'écarter les unes des autres, pour mieux distinguer des images proches.

Les données comptent autant que la méthode. Les auteurs partent de 1,2 milliard d'images du web, retirent les doublons, puis ne gardent que les images proches de jeux de données de référence : on obtient 142 millions d'images variées et de bonne qualité (le jeu LVD-142M). Enfin, ils entraînent un très grand modèle d'un milliard de paramètres, puis transmettent ses connaissances à des modèles plus petits par distillation : le petit modèle apprend à imiter le grand. Le ViT-B/14 utilisé ici a été obtenu ainsi.

Les registres : corriger les artefacts d'attention

En analysant DINOv2, ses auteurs ont découvert un défaut (Darcet et al., 2023, « Vision Transformers Need Registers ») : le modèle détourne quelques patchs de fond peu informatifs

pour y stocker des informations sur l'image entière. Ces patchs reçoivent alors une attention anormale, et les cartes d'attention ne montrent plus ce que le modèle regarde vraiment. La correction consiste à ajouter quatre jetons vides, les registres, qui servent de zone de stockage : les patchs de fond retrouvent leur rôle normal. Je l'ai constaté sur nos propres images : avec la version d'origine, un seul patch de fond, celui du coin en haut à gauche, captait 15,1 % de l'attention (mesure sur 42 images). Avec les registres, il n'en reçoit plus que 0,1 %. J'utilise donc DINOv2 avec registres dans tout le projet.

Ce que cela apporte à ce projet

Le modèle est utilisé gelé : on ne modifie aucun de ses poids, on calcule seulement la représentation de chaque image, et on entraîne par-dessus un classifieur simple (une régression logistique). C'est exactement le cas d'usage visé par les auteurs, et c'est adapté à un petit jeu de 1 050 images qu'un réentraînement complet risquerait d'apprendre par cœur. Sur ImageNet, un simple classifieur linéaire posé sur DINOv2 ViT-B/14 avec registres gelé atteint 84,6 % de bonnes réponses, contre 71,9 % pour MobileNetV2 entraîné de bout en bout.

Le mécanisme d'attention apporte aussi un moyen d'explication : le poids que le jeton [CLS] accorde à chaque patch montre où le modèle a regardé. Je m'en sers pour analyser les décisions du modèle, en le complétant par une méthode qui mesure l'effet réel de chaque zone sur la décision (section 5), et le dashboard affiche cette carte pour chaque prédiction.

La modélisation

Le principe : une seule chose change

La comparaison est construite pour qu'une seule chose diffère d'un modèle à l'autre : le réseau qui transforme l'image en vecteur. Les images, leur préparation, le classifieur posé au-dessus, le découpage en plis et la recherche du réglage sont identiques. Je compare quatre réseaux gelés : deux baselines pré-entraînées de façon supervisée sur ImageNet, MobileNetV2 (celle du projet 6) et ResNet50, et deux tailles de DINOv2 avec registres, DINOv2-reg ViT-S/14 et DINOv2-reg ViT-B/14. ResNet50 et DINOv2-reg ViT-S/14 ont presque la même taille (23,5 et 22,1 millions de paramètres) : leur comparaison sert à savoir si le gain vient de la méthode ou seulement d'un modèle plus gros. Le nouveau modèle retenu, DINOv2-reg ViT-B/14, est fixé à l'avance dans le plan prévisionnel, et non choisi après coup sur les scores, qui sont mes scores de test.

Le classifieur et son réglage

Sur chaque représentation, j'entraîne une régression logistique précédée d'une standardisation des variables. C'est mathématiquement la même chose que la couche « softmax » du projet 6 : une combinaison linéaire des variables, transformée en probabilités. Son seul réglage est C, l'inverse de la force de régularisation : un C petit empêche le modèle d'apprendre par cœur les quelques centaines d'images d'entraînement. C est choisi parmi 7 valeurs, de 0,001 à 1.

La validation croisée imbriquée, groupée et stratifiée

Avec 1 050 images, un seul découpage entraînement / test laisse trop de place au hasard. J'utilise une validation croisée en 5 plis de 210 images : chaque pli sert de test à son tour, le modèle étant entraîné sur les 4 autres. Elle est stratifiée (30 images de chaque catégorie par pli) et groupée (les quasi-doublons restent dans le même pli). Elle est surtout imbriquée : à l'intérieur des 4 plis d'entraînement, une seconde validation croisée choisit C, et le pli de test n'intervient jamais dans ce choix. À la fin, chaque image a été prédite une fois, par un modèle qui ne l'avait jamais vue. Les valeurs de C retenues d'un pli à l'autre vont de 0,001 à 0,010 pour DINOv2-reg ViT-B/14 : toujours une régularisation forte, cohérente avec le petit nombre d'images. Toutes les graines aléatoires sont fixées.

Les métriques

La métrique principale est l'exactitude, la part d'images bien classées. C'est la métrique métier : la part d'articles rangés dans la bonne catégorie. Comme les catégories sont équilibrées, elle n'est pas faussée par une catégorie majoritaire. Je la complète par le F1 macro, qui moyenne la qualité de chaque catégorie et révèlerait une catégorie sacrifiée, par l'intervalle de confiance à 95 % (obtenu en retirant 2 000 fois au hasard 1 050 prédictions), et par le temps de prédiction.

Pour savoir si un écart entre deux modèles est réel, j'utilise le test de McNemar. Il ne regarde que les images sur lesquelles les deux modèles sont en désaccord, et vérifie si l'un réussit nettement plus souvent là où l'autre échoue. Comme je fais 5 comparaisons, je corrige les p-valeurs par la méthode de Bonferroni (multiplication par 5), pour ne pas trouver un écart « significatif » par simple effet du nombre de tests.

Une synthèse des résultats

Le tableau de comparaison

• MobileNetV2 : 83,0 % [0,808 ; 0,852], F1 macro 0,830, 178 erreurs, 2,2 M de paramètres, 36 ms par image

• ResNet50 : 87,9 % [0,859 ; 0,898], F1 macro 0,878, 127 erreurs, 23,5 M de paramètres, 130 ms par image

• DINOv2-reg ViT-S/14 : 89,8 % [0,880 ; 0,915], F1 macro 0,898, 107 erreurs, 22,1 M de paramètres, 166 ms par image

• DINOv2-reg ViT-B/14 : 92,8 % [0,911 ; 0,943], F1 macro 0,927, 76 erreurs, 86,6 M de paramètres, 589 ms par image

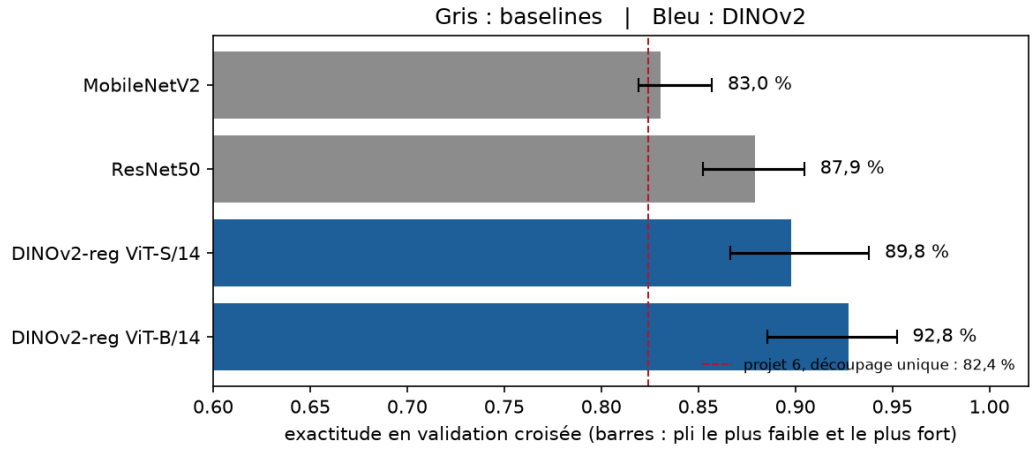


Figure 2 : exactitude en validation croisée ; les barres noires vont du pli le plus faible au plus fort (notebook, section 5).

DINOv2-reg ViT-B/14 atteint 92,8 % de bonnes réponses, contre 83,0 % pour la baseline du projet 6, soit 102 erreurs de moins sur 1 050 images. L'écart est de 9,7 points, avec un intervalle de confiance de [+7,7 ; +11,8] points : il est certain (p-valeur corrigée de 7e-21). DINOv2-reg ViT-B/14 bat aussi ResNet50, de 4,9 points.

À taille comparable, en revanche, le résultat est plus nuancé : DINOv2-reg ViT-S/14 devance ResNet50 de 1,9 point, mais avec une p-valeur corrigée de 0,18, donc l'écart n'est pas distinguable du bruit avec 1 050 images. Je ne peux pas affirmer que la méthode seule explique le gain : la taille du grand modèle y contribue.

Catégorie par catégorie, le gain de F1 va de +1,7 points (Watches, où la baseline avait déjà 0,97) à +13,7 points (Home Decor & Festive Needs). Aucune catégorie n'est sacrifiée. La confusion la plus fréquente de DINOv2-reg ViT-B/14 : Baby Care prise pour Home Furnishing, 12 fois sur 150.

Enfin, le découpage unique du projet 6 (210 images de test) donne 86,7 % à MobileNetV2 et 84,3 % à ResNet50, alors que la validation croisée les classe dans l'ordre inverse. Un seul découpage ne suffit pas pour comparer des modèles proches : c'est ce qui justifie la validation croisée groupée.

Conclusion

La preuve de concept est concluante : DINOv2-reg ViT-B/14 classe nettement mieux les produits que la baseline du projet 6, sans réentraîner le réseau et avec un classifieur très simple. Le gain se paie en calcul : 589 ms par image contre 36 ms pour MobileNetV2 sur mon ordinateur portable, ce qui reste acceptable pour classer des articles au fil de leur mise en ligne.

L’analyse de la feature importance globale et locale du nouveau modèle

Pour une image, les « features » ne sont pas des colonnes comme dans un tableau : ce sont des zones de l'image. J'utilise deux méthodes complémentaires.

Importance locale : une image à la fois

La première est l'attention du jeton [CLS] dans la dernière couche de DINOv2 : le poids qu'il accorde à chaque patch indique où le modèle a regardé pour construire son résumé de l'image. Elle ne coûte rien à calculer, mais elle ne dit pas si la zone a poussé la décision vers la bonne catégorie. La seconde est l'occlusion : je masque successivement chaque zone de l'image avec un carré gris de 56 pixels et je mesure la chute de la probabilité de la catégorie prédite. Elle mesure directement l'effet sur la décision du modèle complet, et s'applique aussi à la baseline.

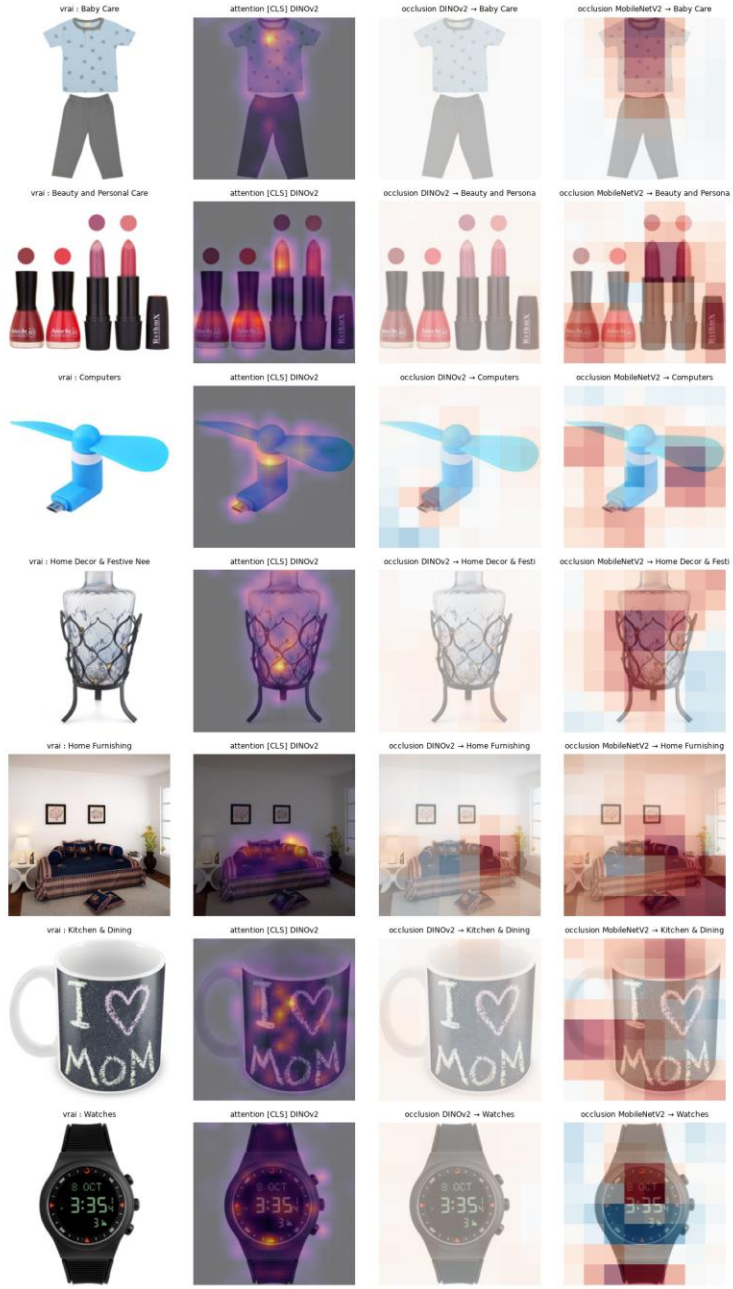


Figure 3 : pour une image par catégorie, l'attention de DINOv2 puis l'occlusion pour DINOv2 et pour MobileNetV2 ; rouge : zone qui soutient la décision (notebook, section 6).

Avec les registres, l'attention se pose sur les objets eux-mêmes. Un exemple parlant : pour un petit ventilateur classé dans Computers, l'attention se concentre sur sa prise USB, la seule partie de l'objet qui le relie à un ordinateur.

Importance globale : en moyenne

Sur les 1 050 images, le produit occupe 54 % de la surface et reçoit 89 % de l'attention de DINOv2 : le modèle regarde le produit plus que le fond. L'occlusion moyenne sur 35 images montre une différence nette entre les deux modèles : masquer le centre de l'image fait chuter la confiance de MobileNetV2 de 4,6 points en moyenne, contre 1,2 pour DINOv2. La décision de MobileNetV2 dépend fortement de la zone centrale ; celle de DINOv2 s'appuie sur l'ensemble de l'image, ce qui la rend plus robuste à un masquage partiel.

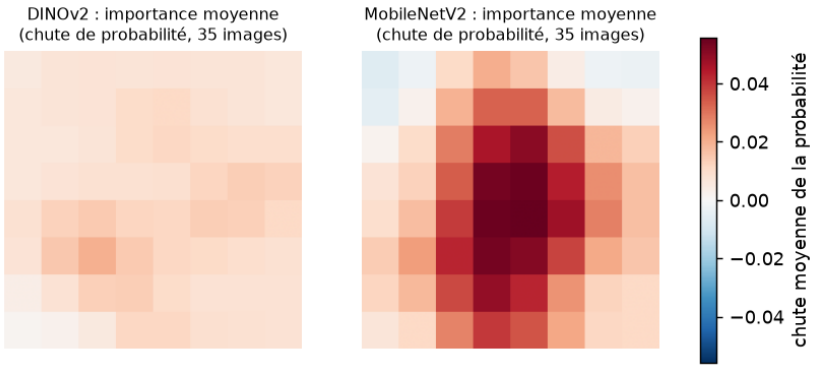


Figure 4 : chute moyenne de la probabilité quand on masque chaque zone, sur 35 images (notebook, section 6).

Les limites et les améliorations possibles

Les limites

• Le jeu est petit : 1 050 images suffisent pour un écart de 10 points, pas pour départager deux modèles proches, comme DINOv2-reg ViT-S/14 et ResNet50.

• Les étiquettes sont imparfaites : 13 paires de photos quasi identiques sont rangées dans deux catégories différentes, ce qui plafonne tout modèle.

• Le coût de calcul est plus élevé que celui de la baseline, et les temps ont été mesurés sur un seul ordinateur portable, sensibles à sa charge.

• L'occlusion explique les décisions zone par zone, avec des carrés de 56 pixels : elle ne descend pas au niveau des détails fins, et l'analyse globale porte sur 35 images seulement.

Les améliorations possibles

• Performance : affiner les dernières couches de DINOv2 sur les images Flipkart, avec une carte graphique et de l'augmentation de données ; combiner la photo et le texte de la description, que le projet 6 avait montré informatif ; corriger les étiquettes en double.

• Interprétabilité : remplacer l'occlusion par des méthodes plus fines comme les valeurs de Shapley sur des groupes de patchs ; montrer dans le dashboard les images du catalogue les plus proches de l'image analysée, une explication par l'exemple que la représentation de DINOv2 rend possible.